PAS – PRAVDĚPODOBNOST-A-STATISTIKA-- ZKOUŠKA-PŘÍPRAVA

Zdeněk Touška

Okruh I – praktické znalosti popisné statistiky

1. Vylosujete si jednu proměnnou a popíšete ji. Vytvoříte pro ni vhodné popisné grafy, spočítáte vhodné popisné statistiky a vše budete ústně komentovat. Proměnná může být libovolného typu.

---

1) Rozhodovací strom: typ proměnné

KROK 1: Je to číslo se smysluplnou aritmetikou?

- ano → **číselná proměnná (4,5,9,2.69,100,0)**
- ne → **kategorická proměnná (žena, moře, a, červená, souhlasím)**

KROK 2 (kategorická): má přirozené pořadí?

- ano → **ordinální** (např. škála 1–5) (spokojený, méně spokojený, mírně nespokojený, nespokojený)
- ne → **nominální** (např. barva, pohlaví) (modrá, červená, oranžová) (žena, muž)

KROK 2 (číselná): nabývá jen „počtů“ (celá čísla) nebo libovolných reálných?

- jen celé počty → **diskrétní (1, 298, 62, 0, 999, 10000)**
- reálné hodnoty (měření) → **spojitá (1.78, 12.5, 0.5)**

A) Číselná proměnná (diskrétní/spojitá)

- **popisné** statistiky **polohy**: průměr, medián, kvantily.
- **variabilita:** rozptyl, směrodatná odchylka, IQR, MAD, koeficient variace.

Grafy):

- **histogram**: tvar rozdělení, koncentrace hodnot
- **boxplot**: medián, kvartily/IQR, případné extrémy

Graf	Pro jaký typ dat	Koukej na (checklist)	Co z toho vyvodit (typické věty)	Použití – jak se používá (kód)
Histogram	Číselná proměnná (jedna)	Tvar rozdělení (zvon / ploché / více špiček) Šikmost (ocas doprava = pravostranná, doleva = levostranná) Počet modusů Podezřelé sloupce na okrajích (outliery) Vliv šířky binů	Rozdělení je přibližně symetrické / pravostranně / levostranně šikmé. Hodnoty jsou koncentrovány kolem … . V datech jsou / nejsou patrné extrémní hodnoty. Rozdělení se (ne)podobá normálnímu.	hist(x) – základní zobrazení rozdělení číselné proměnné
Boxplot	Číselná proměnná (jedna)	Medián (čára v boxu) IQR = výška boxu (variabilita) Vousy Body mimo (odlehlé hodnoty) Poloha mediánu v boxu (náznak šikmosti)	Variabilita je nízká / střední / vysoká (dle IQR). Jsou / nejsou přítomny odlehlé hodnoty (zejména na … konci). Rozdělení působí spíše symetricky / šikmě.	boxplot(x) – medián, IQR a odlehlé hodnoty; boxplot(x ~ g) – porovnání skupin

Dobrovolné zlepšováky (rychlé a „bezpečné“):

- **trimmed mean** nebo **Huberův odhad**, když jsou extrémy a průměr je podezřele posunutý

Hotovo. **Opraveno, zpřesněno, bez bludů:**

Dobrovolné zlepšováky (rychlé a „bezpečné“):

- **trimmed mean** nebo **Huberův odhad**, pokud jsou v datech extrémy a průměr je jimi ovlivněn
- **modus** *pouze pokud je z histogramu zřetelný* (typicky u diskrétní nebo vícemodální proměnné); **není povinný** a **není nutné ho počítat násilně**

B) Kategorická proměnná (nominální/ordinální)

MINIMUM, které po tobě chtějí:

- **absolutní + relativní četnosti**
- **sloupcový + koláčový graf**

Grafy (co z nich čteš):

- **barplot**: dominance kategorií, porovnání četností
- **pie**: podíly (jen doplňkově)

Grafy – základ	barplot()	Sloupcový graf.	barplot(tab)	Sloupcový graf: četnosti kategorií/známek.
Grafy – základ	pie()	Koláčový graf.	pie(tab)	Koláčový graf: podíly kategorií (když je málo kategorií).

Statistiky:

- tabulka absolutních četností, relativní četnosti

- u ordinální: dává smysl zmínit pořadí, případně kumulativní četnosti (pokud chceš extra bod)

3) R šablona příkazů (placeholdery {df}, {X})

Číselná proměnná

```r
x <- {df}${X}

# grafy
hist(x)
boxplot(x)

# popisné statistiky (poloha + variabilita)
summary(x)
quantile(x, probs = c(0, .25, .5, .75, 1))
mean(x); median(x)
var(x); sd(x)
IQR(x); MAD(x)
CoefVar(x)      # pokud je ve tvých skriptech/doporučených funkcích
mean(x, trim=0.10)   # volitelné
HuberM(x)            # volitelné
```

Kategorická proměnná

```r
x <- {df}${X}

# četnosti
tab <- table(x)
tab
prop.table(tab)

# grafy
barplot(tab)
pie(tab)
```

---

4) Šablona ústního komentáře (8–10 vět)

1. „Vybral jsem proměnnou {X}; jde o **(číselnou/kategorickou)** proměnnou, protože …“
2. „Nejprve ukazuji základní grafy: **(histogram+boxplot / barplot+koláč)**, protože přesně ty se zde požadují.“
3. „Z histogramu/barplotu je vidět, že nejčastější oblast/kategorie je … a rozložení je …“
4. „U číselné proměnné shrnu polohu: průměr je …, medián je … (porovnání: blízko/daleko).“
5. „Variabilita: sd je …, IQR je …, tedy data jsou (málo/středně/hodně) rozptýlená.“
6. „Boxplot ukazuje medián a kvartily; pokud jsou vidět extrémy, mohou ovlivnit průměr.“
7. „Proto případně doplním robustní střed (trimmed/Huber), aby byl odhad polohy méně citlivý na extrémy.“
8. „U kategorické proměnné: absolutní a relativní četnosti ukazují, že dominuje … s podílem …“
9. „Závěr: proměnná {X} má typické hodnoty kolem … / nejčastěji nabývá … a rozložení je …“

OKRUH II

Okruh II – co skutečně umět

1) Bodové a intervalové odhady (průměr, rozdíl průměrů, podíl, rozdíl podílů)

- **Co to je: odhad parametru populace ze vzorku (jedno číslo vs. interval).**
- **Umět: spočítat, znát vzorce, říct odkud se bere variabilita (SE).**
- **Rozlišit: bodový × intervalový odhad (jistota vs. nejistota).**
- **Kdy použít: interval vždy, bodový jen orientačně.**

2) Testování statistických hypotéz

- **Co to je: rozhodování, zda data odporují H_0.**
- **Umět: sestavit test (H_0, H_1, α, test, p-hodnota), vybrat správný test.**
- **Interpretace: $p \leq \alpha \Rightarrow$ zamítám H_0 (ne „H_0 je nepravda“).**
- **Předpoklady: normalita, nezávislost, rozptyl (když ne → robustní/bootstr.).**

3) Vztah dvou číselných proměnných

- **Co sleduji: tvar, směr, sílu vztahu.**
- **Nástroje: korelace (Pearson/Spearman), kovariance, korelační matice.**
- **Pozor: korelace ≠ kauzalita, selhává u nelineárních vztahů.**

4) Regresní přímka

- **Co to je: model závislosti Y na X.**
- **Umět: rovnici, význam β_0, β_1, metoda nejmenších čtverců.**
- **Interpretace: koeficienty, p-hodnoty, R^2.**
- **Předpoklady: linearita, normalita reziduí, homoskedasticita.**

5) Podkladové rozdělení dat

- **Cíl: zjistit, jaké rozdělení data přibližně mají.**
- **Nástroje: histogram, KDE, QQ-plot.**
- **Smysl: správná volba testu a intervalu.**

6) Normalita a tvar rozdělení

- **Co hodnotím: symetrie, šikmost, špičatost.**
- **Testy + grafy: Shapiro-Wilk, QQ-plot.**
- **CLV: průměry se blíží normále, ne data samotná.**

7) Odlehlé hodnoty

- **Co to je: extrémní pozorování s velkým vlivem.**
- **Nástroje: boxplot, IQR, transformace.**
- **Řešení: robustní metody, ne slepé mazání.**

OKRUH III

(1) Klasifikace proměnných a typů dat (stručně)

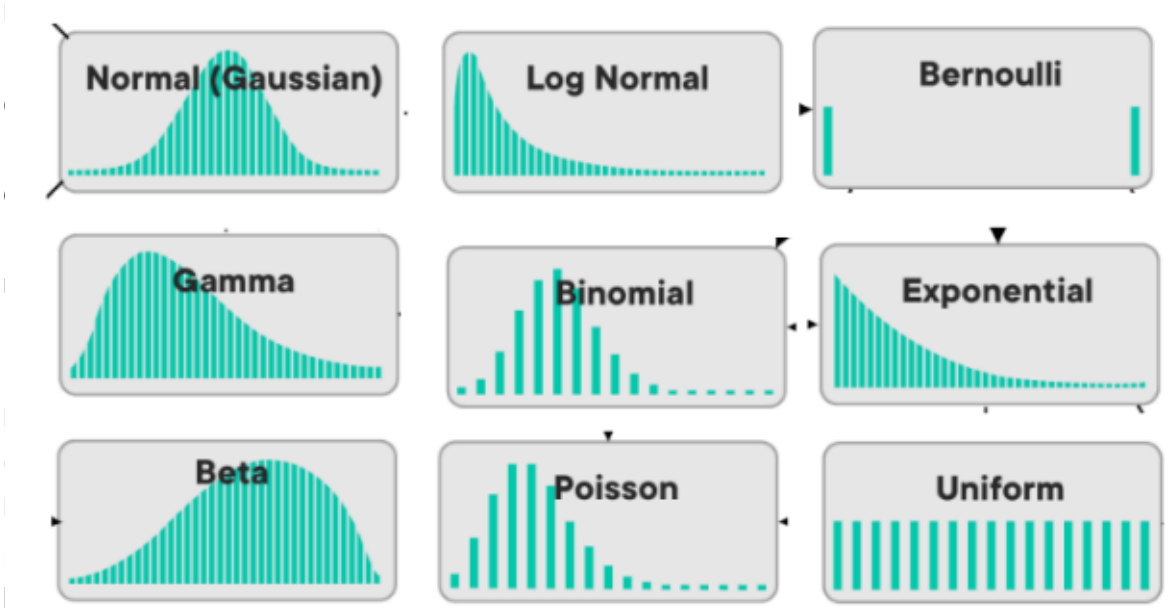

Rozdělení je teoreticky **model chování veličiny v populaci**, empirická distribuční funkce je jeho odhad ze vzorku.
Vlastnosti rozdělení se shrnují číselně: **střední hodnota** (typická poloha), **rozptyl** (variabilita) a **modus** (nejpravděpodobnější hodnota / maximum hustoty), přičemž ne vždy musí být definované.

Okruh 3 – (3) Spojité a (4) diskrétní náhodné veličiny

Spojitá náhodná veličina je popsána **hustotou pravděpodobnosti** (pravděpodobnost na intervalu) a **distribuční funkcí** (pravděpodobnost $X \leq x$); pravděpodobnost konkrétní hodnoty je nulová.

Typická spojitá rozdělení jsou **normální** (symetrické, dané μ, σ),
exponenciální (čas do události, parametr (\lambda)),
gamma (čas do více událostí), **beta** (podíly v ⟨0,1⟩), **χ^2**
lognormální (kladná, pravostranně zkosená).

Diskrétní náhodná veličina je popsána **pravděpodobnostní funkcí** (pravděpodobnost konkrétní hodnoty) a distribuční funkcí.
Základní diskrétní rozdělení jsou **Bernoulliho** (0/1),
binomické (počet úspěchů),
Poissonovo (počty událostí),
geometrické (čekání na první úspěch),
hypergeometrické (výběr bez náhrady)
diskrétní rovnoměrné.

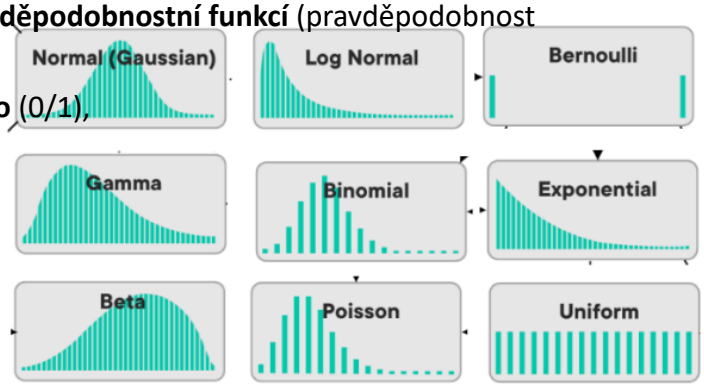

(5) Tradiční vs. robustní přístupy k odhadování — zkouškový extrakt

Tradiční přístup používá průměr, rozptyl, SD, Pearsonovu korelaci a OLS regresi; je **efektivní**, ale **silně citlivý na outliery** a spoléhá na **normalitu, linearitu a homoskedasticitu**.

Robustní přístup (medián, MAD, IQR, trimmed mean, Spearman, Huber) je **odolný vůči extrémům** a funguje i při **porušených předpokladech**, typicky u malých nebo asymetrických dat.
Volba je jednoduchá:

čistá, symetrická data → tradiční

špinavá / s outliery → robustní.
Huberův odhad je **kompromis**: zachová informaci z extrémů, ale s omezeným vlivem.

---

(6) Bodový vs. intervalový odhad

Bodový odhad dává **jedno číslo** jako odhad parametru populace (např. průměr), ale **neříká nic o nejistotě**.
Intervalový odhad určuje **interval**, ve kterém se s danou spolehlivostí (např. 95 %) nachází skutečný parametr populace.
Šířka intervalu závisí na **standardní chybě**, **kritické hodnotě (Z nebo t)** a velikosti výběru.
Z-kvantil se používá při známém rozptylu nebo velkém n, **t-kvantil při neznámém rozptylu a malém n**.

---

(7) Tradiční vs. bootstrapový přístup k statistické inferenci

Statistická (inferenční) statistika slouží k **odhadu parametrů populace a testování hypotéz** na základě výběru.
Tradiční přístup používá analytické vzorce (bodové/intervalové odhady, testy), ale **vyžaduje splnění předpokladů** (např. normalitu).
Bootstrapový přístup je **neparametrický**, využívá **opakované resamplingy s náhradou** a z empirické distribuce statistik odhaduje **intervaly spolehlivosti, standardní chyby a p-hodnoty**.
Bootstrap je vhodný při **porušených předpokladech nebo malém vzorku**, ale vyžaduje **reprezentativní a nezávislá data**.

(8) Zákon velkých čísel a centrální limitní věta – význam a využití

Zákon velkých čísel (ZVČ) říká, že **s rostoucím počtem pozorování se výběrový průměr blíží skutečné střední hodnotě populace**, pokud tato existuje.
Používá se hlavně k **odůvodnění odhadu střední hodnoty z velkého vzorku** (průzkumy, experimenty, simulace, hazard).

Centrální limitní věta (CLV) říká, že **rozdělení průměrů z dostatečně velkých nezávislých vzorků je přibližně normální**, bez ohledu na tvar původního rozdělení (pokud má konečný rozptyl).
Je klíčová pro **intervaly spolehlivosti, hypotézové testy (z-test, t-test), regresi a ANOVA**, protože umožňuje používat normální (nebo t) kvantily i pro nenormální data.

Shrnutí rozdílu:

- ZVČ: *kam průměr míří* (konvergence k μ)
- CLV: *jak se chová rozdělení průměrů* (→ normální)

(9) Přístupy k testování statistických hypotéz

Statistické testování hypotéz je postup, kterým na základě dat rozhodujeme, zda jsou pozorované výsledky slučitelné s nulovou hypotézou.
Nulovou hypotézu **nezamítáme nebo zamítáme**, nikdy ji nepřijímáme; zamítnutí znamená, že data jsou s H_0 v rozporu.
Rozhodnutí se provádí pomocí **p-hodnoty** a **hladiny významnosti α**, případně porovnáním testovací statistiky s kritickou hodnotou.
Interval spolehlivosti je ekvivalentní pohled, který ukazuje, jaké hodnoty parametru jsou s daty kompatibilní.

Jednovýběrový t-test -
Testuje, zda se **průměr populace** statisticky liší od **konkrétní zadané hodnoty**, za předpokladu normality.

Jednovýběrový Wilcoxonův test -> alternativa T-test
Neparametrická alternativa k jednovýběrovému t-testu, testuje **medián** proti dané hodnotě.

Shapiro–Wilkův test -> Normalita ?
Testuje, zda **data pocházejí z normálního rozdělení** (H_0: normalita).

Dvouvýběrový t-test
Testuje, zda se **průměry dvou nezávislých skupin** statisticky liší (při normalitě).

Dvouvýběrový Wilcoxonův test (Mann–Whitney) -> alternativa dvouvýběrový
Neparametrická alternativa k dvouvýběrovému t-testu, porovnává **rozdělení/mediány** dvou skupin.

ANOVA – průměry tri a vice se lisi ?
Testuje, zda se **průměry tří a více skupin** liší, za předpokladu normality reziduí a shody rozptylů.

Kruskal–Wallisův test – alternative ANOVA
Neparametrická alternativa k ANOVĚ, porovnává **rozdělení více skupin**.

Dunnův test
Následný (post-hoc) test po Kruskal–Wallisově testu, určuje **které dvojice skupin se liší**.

Tukey HSD
Post-hoc test po ANOVĚ, porovnává **všechny dvojice průměrů** při kontrole chyby I. druhu.

χ^2 test nezávislosti -KATEGORIALNI 2
Testuje, zda mezi **dvěma kategoriálními proměnnými** existuje statisticky významná asociace.

Fisherův exaktní test
Alternativa k χ^2 testu pro **malé četnosti**, poskytuje přesné p-hodnoty.

Cohenovo d
Míra efektu vyjadřující **velikost rozdílu průměrů** ve směrodatných odchylkách.

Hedgesovo g
Upravené Cohenovo d pro **malé vzorky**.

Glassovo Δ (delta)
Míra efektu používající **směrodatnou odchylku kontrolní skupiny**.

Fisherovo η^2 (eta squared)
Míra efektu v ANOVĚ vyjadřující **podíl vysvětlené variability**.

Haysova ω^2 (omega squared)
Robustnější míra efektu v ANOVĚ, méně nadhodnocuje skutečný efekt.

Cramerovo V
Míra **síly asociace** mezi dvěma kategoriálními proměnnými (obecná kontingenční tabulka).

Hotellingův T^2 test
Mnohorozměrná obdoba t-testu, porovnává **vektory středních hodnot** dvou skupin.

MANOVA
Mnohorozměrná ANOVA, testuje rozdíly mezi skupinami pro **více závislých proměnných současně**.

---

(10) Interpretační problémy intervalového odhadu, p-hodnoty, kovariance a korelace

Statistická významnost (p-hodnota) říká, zda je pozorovaný efekt pravděpodobně náhodný, ale **neříká nic o jeho praktické důležitosti** (věcná významnost).
U **malých vzorků** jsou p-hodnoty nestabilní a intervaly spolehlivosti široké, u **velkých vzorků** mohou vycházet statisticky významné i **zanedbatelné efekty**, proto je nutné sledovat velikost efektu a kontext.
Kovariance je obtížně interpretovatelná, protože **závisí na jednotkách měření** a hodnotí jen lineární vztah.
Korelace je standardizovaná (−1 až 1), ale **měří pouze lineární souvislost, je citlivá na outliery a nevyjadřuje kauzalitu**.

(11) Populace, výběr a populační vs. výběrové charakteristiky

Populace je soubor všech zkoumaných prvků (konečná; „nekonečná“ jen teoreticky), z níž získáváme **výběr**.
Náhodný výběr (prostý, systematický, stratifikovaný) zajišťuje reprezentativnost, zatímco **nenáhodný výběr** (kvótní, účelový, z pohodlí) je rychlejší, ale může být zkreslený.
Experiment sbírá data v kontrolovaných podmínkách a jako jediný umožňuje studium **kauzality**.
Populační charakteristiky (parametry) se obvykle neznají a **odhadují se výběrovými charakteristikami**, přičemž větší vzorek snižuje chybu odhadu.

---

(12) Frekvenční rozdělení a frekvenční křivka

Frekvenční rozdělení je **tabulka četností** hodnot (diskrétní) nebo intervalů (spojité), frekvenční křivka je jejich **grafické znázornění** (histogram, případně hladká křivka).
Šikmost (koeficient S) popisuje **asymetrii rozdělení**: $S > 0$ pravostranná, $S < 0$ levostranná, hodnotí se u **unimodálních** rozdělení.
Špičatost (koeficient K) popisuje **koncentraci hodnot kolem modu a chvosty**:

$K > 0$ leptokurtická (okolo modu i odlehle), $K = 0$ mezokurtická (vypada jako normalní),

K < 0 platykurtická.

---

(13) Jádrový odhad hustoty a modus

Jádrový (kernelový) odhad hustoty je **neparametrický odhad hustoty pravděpodobnosti spojité proměnné**, který vytváří hladkou frekvenční křivku bez intervalového třídění.
Hlavní parametry jsou **kernel K** (váhová funkce) a **bandwidth h** (šířka pásma): malé *h* → detailní, „roztřesený“ odhad, velké *h* → hladký, ale může skrýt strukturu.
Modus u spojité proměnné je **lokální maximum jádrového odhadu hustoty**, u diskrétní proměnné hodnota s nejvyšší četností.
Počet lokálních maxim určuje **modalitu rozdělení** (uni-, multi-, antimodální).

---

(15) Vlastnosti popisných statistik – posunutí a změna měřítka

Popisné statistiky **shrnuji data** a zároveň slouží jako **odhady populačních parametrů** (např. průměr → populační střední hodnota, rozptyl → variabilita).
Posunutí ((x \to x + a)) mění polohové charakteristiky (průměr, medián, modus se posunou o (a)), ale **nemění variabilitu ani tvar** (rozptyl, směrodatná odchylka, šikmost, špičatost).
Změna měřítka ((x \to b x)) násobí polohové statistiky (b), rozptyl se násobí (b^2), směrodatná odchylka (|b|), **tvarové charakteristiky zůstávají stejné** (u záporného (b) se otočí znaménko šikmosti).
Šikmost a špičatost popisují **tvar rozdělení**, jsou bezrozměrné a invariantní vůči posunutí; variační koeficient je **relativní míra variability** a je invariantní vůči změně měřítka.
Robustní odhady (medián, trimmed mean, Huberův odhad) jsou méně citlivé na outliery než aritmetický průměr, ale reagují na posunutí a měřítko stejně jako průměr.

---

(16) Normování proměnné a jeho význam

Normování (min–max) převádí data na interval ⟨0,1⟩ a používá se hlavně tam, kde záleží na **rozsahu hodnot** nebo na **nezápornosti** (ML algoritmy, vizualizace), nikoli na statistické inferenci.

Standardizace (Z-skóre) převádí data na **střed 0 a směrodatnou odchylku 1**, čímž odstraňuje vliv měřítka a zachovává tvar rozdělení.
Standardizace je klíčová pro **šikmost, špičatost, intervaly spolehlivosti, korelaci a testování hypotéz**, protože umožňuje používat **kvantily normálního nebo t-rozdělení**.
Bez standardizace by bylo nutné používat jiné kvantily pro každé měřítko, což by znemožnilo obecné inferenční vzorce.

(17) Regresní model – účel a odhad (jednoduchá lineární regrese)

Jednoduchá lineární regrese modeluje **lineární závislost** mezi nezávislou proměnnou (x) a závislou proměnnou (y) pomocí vztahu

$y = \beta_0 + \beta_1 x + \varepsilon$, kde β_0 je absolutní člen a β_1 směrnice.

Koeficienty β_0, β_1 se odhadují **metodou nejmenších čtverců**, která minimalizuje součet čtverců reziduí (aby se kladné a záporné odchylky nevyrušily).
Model předpokládá **linearitu, normalitu chyb, homoskedasticitu a nezávislost chyb**.
Koeficient determinace (R^2) udává, jakou část variability (y) model vysvětluje.

---

(18) Předpoklady lineární regrese — rychlá zkoušková verze

1. **Linearita**
   Vztah mezi (X) a (Y) musí být lineární, jinak je model systematicky špatně specifikovaný.
2. **Normalita chyb**
   Rezidua mají normální rozdělení → nutné pro správné p-hodnoty a intervaly spolehlivosti.
3. **Homoskedasticita**
   Rozptyl chyb je konstantní pro všechna (X) (žádný „trychtýř“).
4. **Nezávislost chyb**
   Rezidua jsou na sobě nezávislá (často porušeno u časových řad).
5. **Bez vlivných outlierů**
   Extrémní hodnoty nesmí dominovat odhadu koeficientů.
6. **Stabilita rozptylu**
   Variabilita chyb se nemění s velikostí prediktoru (prakticky totéž co homoskedasticita).
7. **Nezávislost měření**
   Jednotlivá pozorování nejsou mezi sebou závislá.

8. **Bez multikolinearity (u víc prediktorů)**
   Nezávislé proměnné nesmí být silně korelované, jinak jsou koeficienty nestabilní.

Jednovětá nouzovka ke zkoušce:
Lineární regrese předpokládá lineární vztah, normální a nezávislá rezidua s konstantním rozptylem, bez extrémních outlierů a bez silné korelace mezi prediktory.

(14) Histogram – citlivost na šířku binu a offset

Histogram zobrazuje rozdělení dat pomocí intervalů (binů); **šířka binu** určuje míru detailu (malá → šum, velká → ztráta struktury) a **offset** posouvá začátek binů, což může změnit vzhled tvaru.
Špatná volba obou může **zkreslit dojem o šikmosti, počtu modů i outlierech**, aniž by se změnila samotná data.
Histogram slouží hlavně k **orientačnímu posouzení tvaru rozdělení**, ne k přesným závěrům.
Správná praxe: **zkusit více šířek/offsetů a porovnat s KDE nebo boxplotem**.